

**INFORME N° 001-2021-GRMC**

Señor : Dr. **SAMUEL GUSTAVO HUAMÁN BUSTAMANTE**  
Coordinador de Procesamiento Digital de Señales, Imágenes e  
Inteligencia Artificial de la Dirección de Investigación y Desarrollo  
Tecnológico  
INICTEL-UNI

Asunto : Primer entregable de servicio de apoyo en la investigación  
científica 2

Referencia : Orden de servicio N° 635

Fecha : San Borja, diciembre de 2021

---

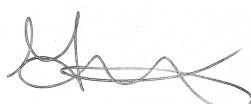
---

Me dirijo a usted, a fin de remitirle adjunto al presente el primer entregable correspondiente a la orden de servicio N.º 635, con título:

**“INFORME TÉCNICO REFERENTE A ANÁLISIS DE DEFICIENCIA  
HÍDRICA A PARTIR DE IMÁGENES MULTIESPECTRALES  
OBTENIDAS POR VÍA UAV”**

Es todo cuanto cumple con informar a usted para los fines pertinentes.

Atentamente,



Guillermo Ricardo Moreno Carrillo  
DNI N° 72467067



Universidad Nacional de Ingeniería

INSTITUTO NACIONAL DE INVESTIGACIÓN Y  
CAPACITACIÓN DE TELECOMUNICACIONES

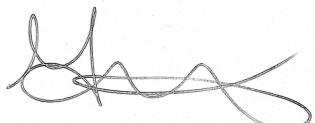
INFORME TÉCNICO  
REFERENTE A ANÁLISIS DE  
DEFICIENCIA HÍDRICA A  
PARTIR DE IMÁGENES  
MULTIESPECTRALES  
OBTENIDAS POR VÍA UAV

Autor:

Guillermo Ricardo Moreno Carrillo

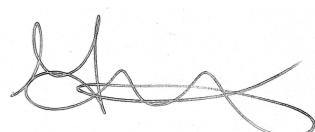
“DIRECCIÓN DE INVESTIGACIÓN DE DESARROLLO  
TECNOLÓGICO”

- 2021 -



## ÍNDICE

<b>Generación de funcionalidades para base de datos</b>	<b>4</b>
Implementación y uso	4
Observaciones	5
<b>Pre-análisis segmentación de zona de interés</b>	<b>5</b>
Implementación	5
Resultados	7
Observaciones	7
<b>Descriptores propuestos</b>	<b>7</b>
HSV	8
LAB	9
Porcentaje de oscuros	9
Máscara basada en entropía	10
<b>Análisis de descriptores</b>	<b>10</b>
Análisis de dispersión en el tiempo	11
Análisis de importancia de parámetros	15
<b>Discusión</b>	<b>20</b>
<b>Conclusiones</b>	<b>20</b>



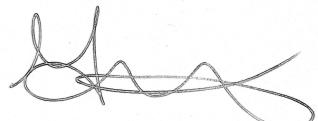
## 1. Generación de funcionalidades para base de datos

Uno de los pasos previos al análisis y diseño de modelos estadísticos para predicción y clasificación, es necesario desarrollar módulos de funcionalidades para el tratamiento de la base de datos. De esta forma, la implementación de métodos avanzados de predicción será más rápida. Asimismo, la implementación de procesos de preprocesamiento se realizará de manera más sencilla.

### a. Implementación y uso

Para implementación de este módulo, se tomó en cuenta las posibles necesidades futuras para el análisis de las imágenes, y en función de estas se desarrollaron las funcionalidades para la carga de la base de datos. Entre estas funcionalidades se tiene:

- Módulo de carga específico para el tipo de ordenamiento realizado.
- Ordenamiento de base de datos de forma que se agilice el posterior procesamiento de la información.
- Tratamiento de la información temporal (vuelos) y geográfica (posición e identificación) para su utilización en posterior análisis.
- Procesamiento de la información posicional para el etiquetado de datos y procesamiento en posteriores métodos.
- Carga de información en imágenes disponibles (Phantom RGB, Sentera RGB, Sentera NIR, Máscaras de segmentación para Sentera).
- Regularización automática de las imágenes para generar una base de datos con la misma información en todos los tipos de imágenes, esta funcionalidad se implementó debido a que hay imágenes obtenidas por la cámara Phantom que no se tienen con la Sentera y viceversa.
- Implementación de módulo de aplicación de transformaciones de preprocesamiento.
- Ordenamiento y carga de metadata disponible de cada imagen.
- Opción para la obtención únicamente de metadata e información temporal y geográfica de imagen. Esta opción fue implementada para evitar el retardo producido por la carga de imágenes, en caso de que solo se necesite la información de la metadata.



i. Entrada

Instanciación:

```
Dataset=Dataset_direct(root_dir='Data_Base_directory',
                      ImType=['PhantomRGB', 'SenteraRGB', 'SenteraNIR'],
                      days='*',
                      months='*',
                      Trees_col='*',
                      Trees_fil='*',
                      Intersec=False,
                      transform=None,
                      retrieve_img=True)
```

Uso:

```
Dat01=Dataset[0]
```

b. Observaciones

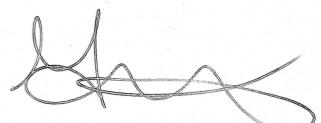
La instancia de elementos del dataset, es lenta debido a la carga computacional del preprocesamiento que se implemente. Esto se vio reflejado en al implementar una transformación de preprocesamiento de segmentación. Por lo tanto, es recomendable realizar el preprocesamiento fuera de línea y generar nueva data para evitar retardos de procesamiento muy prolongados durante el entrenamiento de modelos.

## 2. Pre-análisis segmentación de zona de interés

Para mejorar la precisión de posteriores modelos de clasificación, se realizó un preprocesamiento de filtrado de ruido, en este caso, se considera ruidos todo lo que en la imagen no se considera objeto de análisis, por lo tanto se evita realizar procesamiento sobre los píxeles que no forman parte de la copa del árbol. Por ello se realizó el diseño de un algoritmo de segmentación para la copa de los árboles obtenida con la cámara Phantom.

a. Implementación

El flujo total de la implementación de segmentación se muestra en la fig. 1. La primera parte del procesamiento es transformar la imagen a el espacio de colores HSV y se toma únicamente el canal de matiz, debido a que hay más contraste de la copa con el resto de la imagen. Posteriormente se segmentan los pixeles correspondientes a los matices de color verde y cercanos. El resultado de este procesamiento tiene formas no correspondientes a la forma del árbol, debido a un cable de color negro que pasa por todas las imágenes, esto de filtro con una operación morfológica de erosión con mascara cuadrada. Posteriormente, se cerraron los hoyos de la imagen y se escogió el contorno más grande como la



máscara de la copa del árbol.

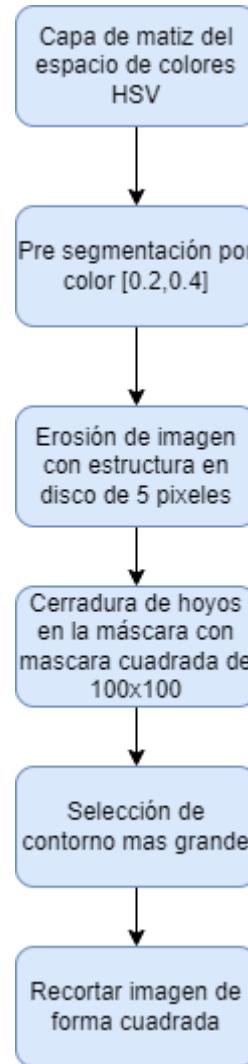


fig. 1: diagrama de flujo de segmentación

## b. Resultados

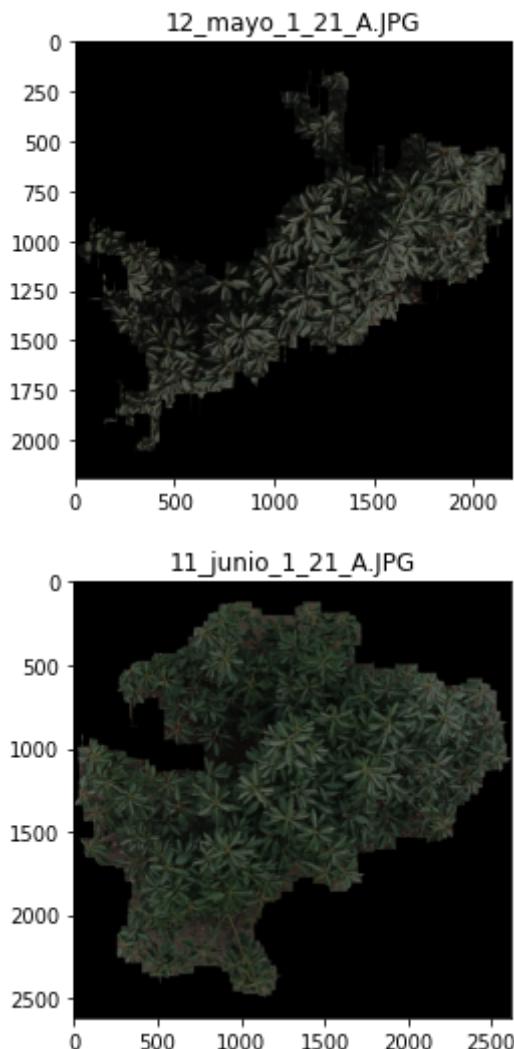


fig 2: resultado del proceso de segmentación

## c. Observaciones

El método es eficaz para la gran mayoría de imágenes. Sin embargo, los fallos que se encontraron no son de gran importancia debido a que segmentan más del 50% de la copa del árbol. Se implementó la posibilidad de que la máscara sea cuadrada y que la salida muestre el suelo contenido en la forma cuadrada, por si es necesario realizar el análisis de esas zonas de la imagen.

## 3. Descriptores propuestos

Basado en la observaciones de estudios pasados y recomendaciones de los especialistas en el campo de biología a cargo del proyecto se seleccionaron diferentes descriptores que podrían servir para clasificar el tipo de deficiencia del árbol. Estos descriptores están mencionados en los siguientes incisos.

### a. HSV

Dado que el color de los árboles con deficiencias tienden a cambiar el color de sus hojas, se usa el espacio de matiz de HSV. Se esperaría que la variación de colores en este espacio sea un indicador importante para la detección de deficiencias.

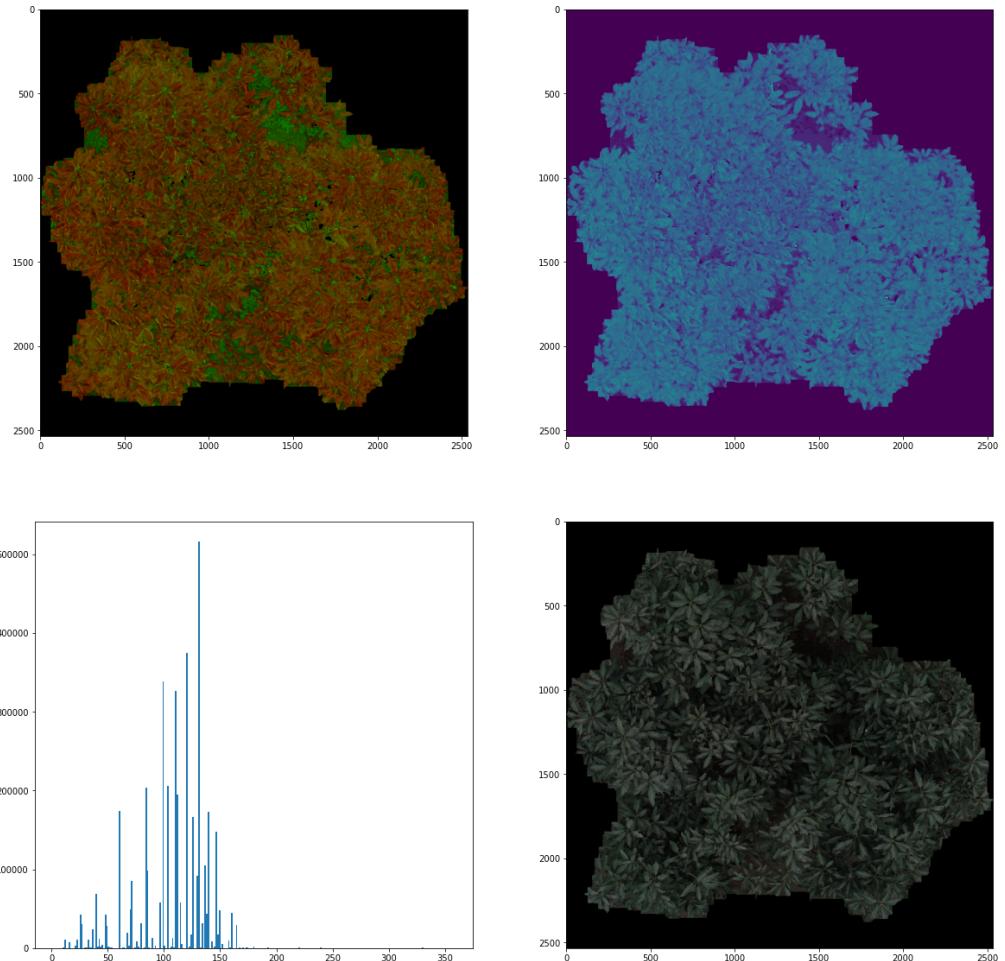


fig. 3: análisis del canal H de HSV. imagen superior izquierda espacio de color HSV. Imagen superior derecha canal H. Imagen inferior izquierda histograma de canal H. Imagen inferior derecha imagen original.

Se escogió como descriptor la media, moda y varianza de la distribución de los pixeles en el canal H.

A handwritten signature in black ink, appearing to read "Fernando J. González".

### b. LAB

Otro indicador sugerido son los hoyos en la copa de los árboles. Se selecciono el canal L del espacio de color Lab debido a que este refleja el rango de colores negros o blancos. Y se espera que los hoyos aumenten la cantidad de píxeles oscuros en la imagen.

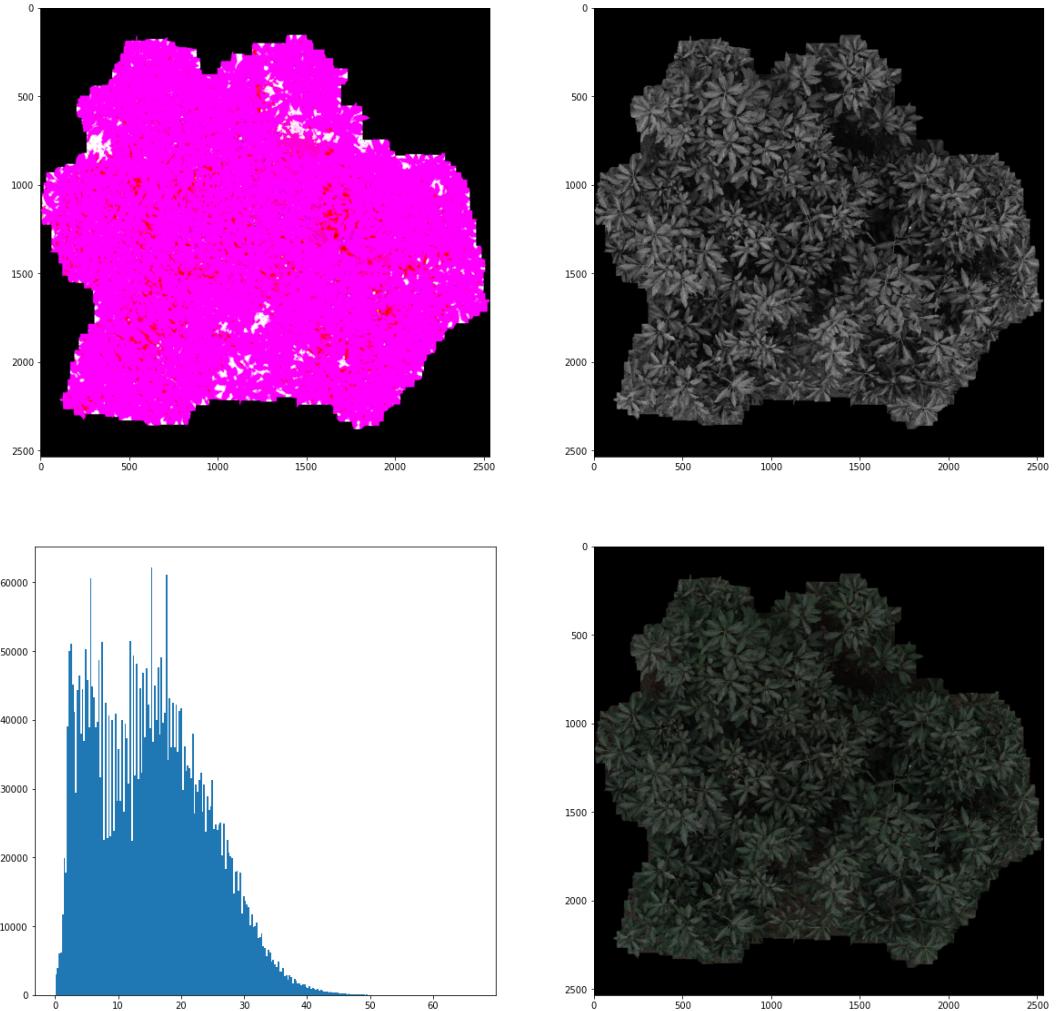
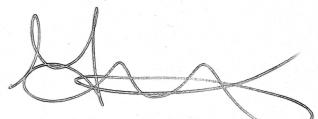


fig. 4: análisis del canal H de HSV. imagen superior izquierda espacio de color Lab. Imagen superior derecha canal L. Imagen inferior izquierda histograma de canal L. Imagen inferior derecha imagen original.

Se escogió como descriptor la media, moda y varianza de la distribución de los píxeles en el canal L.

### c. Porcentaje de oscuros

En general, se observó que la distribución de los píxeles en la capa L del espacio de colores Lab tiene 2 valores máximos locales. Por ello se considera que el primer valor máximo corresponde a los hoyos de la copa de los árboles. Se tomó



como descriptor todos la razón entre todos los valores menores a 10 en el canal L sobre todos los píxeles de la máscara, en otras palabra la razón de píxeles oscuros de la copa del árbol.

#### d. Máscara basada en entropía

Otra de las medidas está basada en la forma de las hojas. Debido a que es normal que las hojas se “doblen” debido a la falta de nutrientes. La transformación espacial basada en entropía realza los bordes de los elementos en la imagen. Por qué se puede obtener mayor información de la forma de hoja.

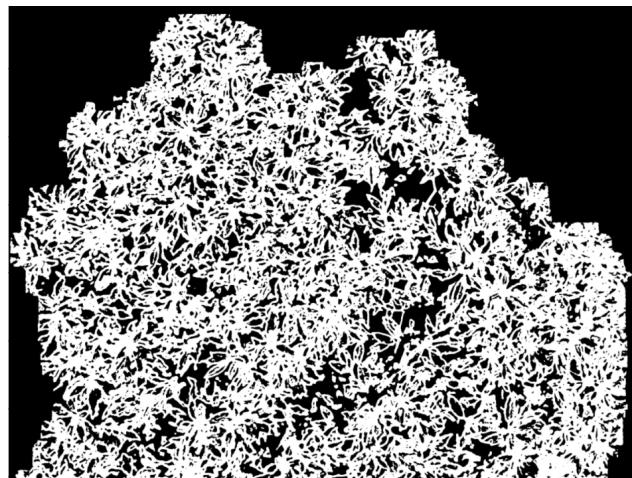
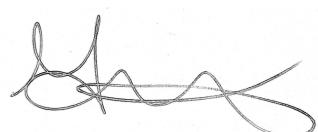


fig. 5.: Resultado de la imagen basada en entropía

## 4. Análisis de descriptores

Se realizó un análisis general con todos descriptores propuestos anteriormente. Primero se realizó el análisis de dispersión de las características en el tiempo. Posteriormente se realizó el análisis de la importancia de los descriptores si estos fueran usados para clasificar las imágenes.



### a. Análisis de dispersión en el tiempo

#### i. Porcentaje de píxeles oscuros

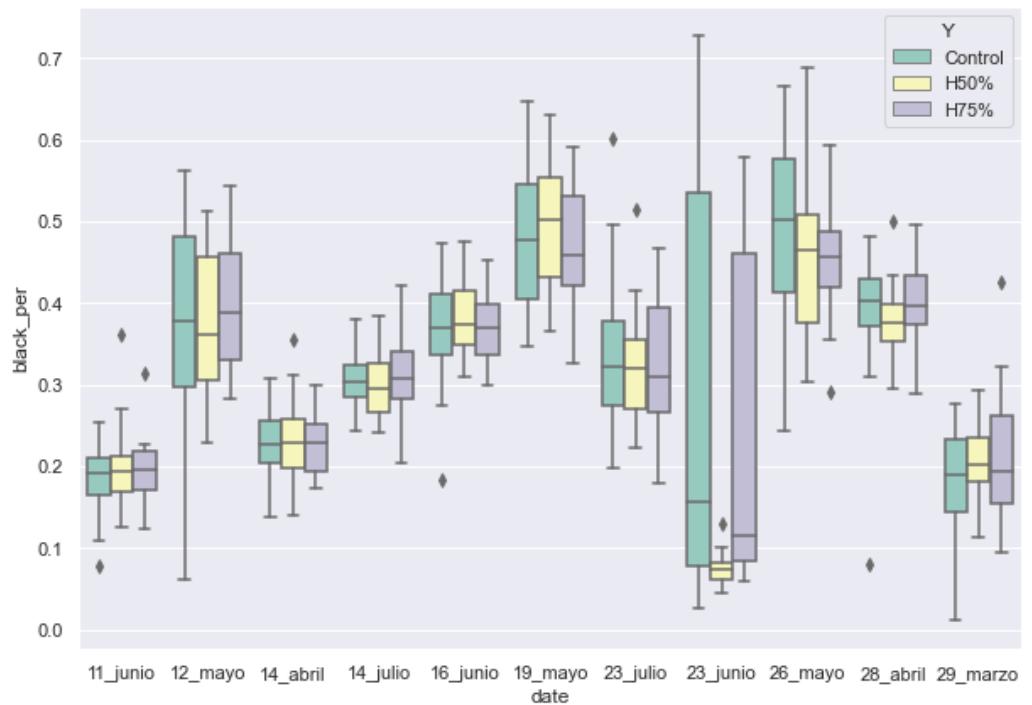


fig. 6: Gráfico de dispersión de datos por vuelo de los datos de porcentaje de píxeles oscuros en la copa de árbol

Este descriptor no muestra gran capacidad de separabilidad entre las clases de deficiencia dentro de la deficiencia hídrica. Excepto por algunos meses como mayo y junio, donde la mayor cantidad de zonas oscuras es mayor. Lo cual no es el comportamiento esperado. Por lo que este descriptor podría no ser útil.

ii. Canal L del espacio de color Lab

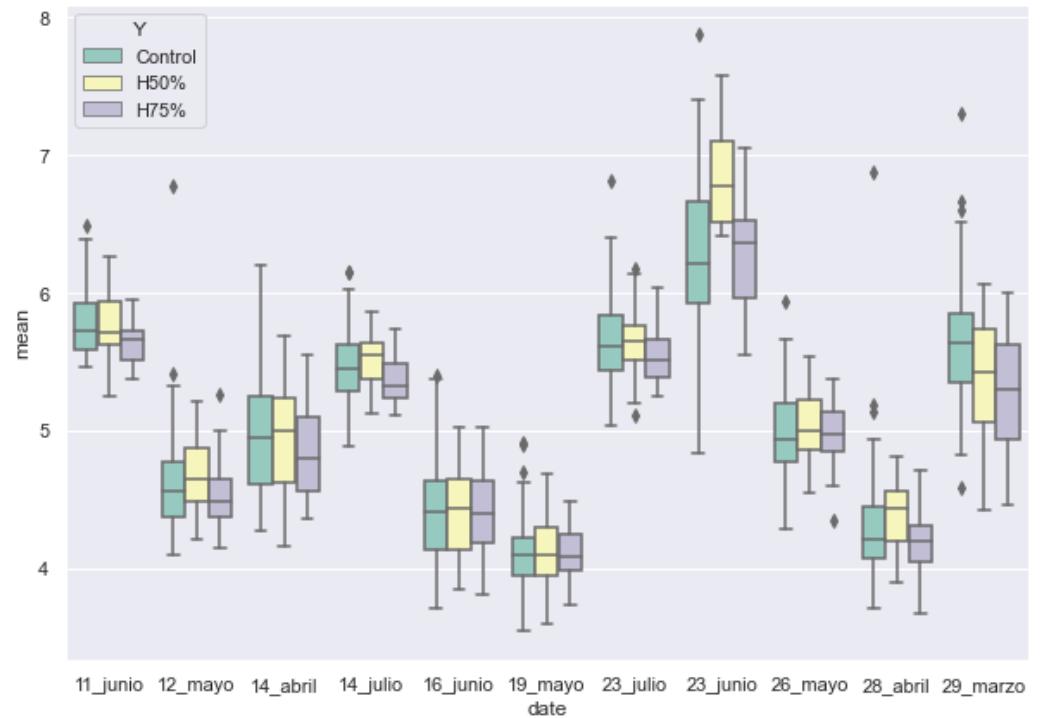


fig. 7: Gráfico de dispersión de datos por vuelo de media de valores en el canal L de la copa del árbol

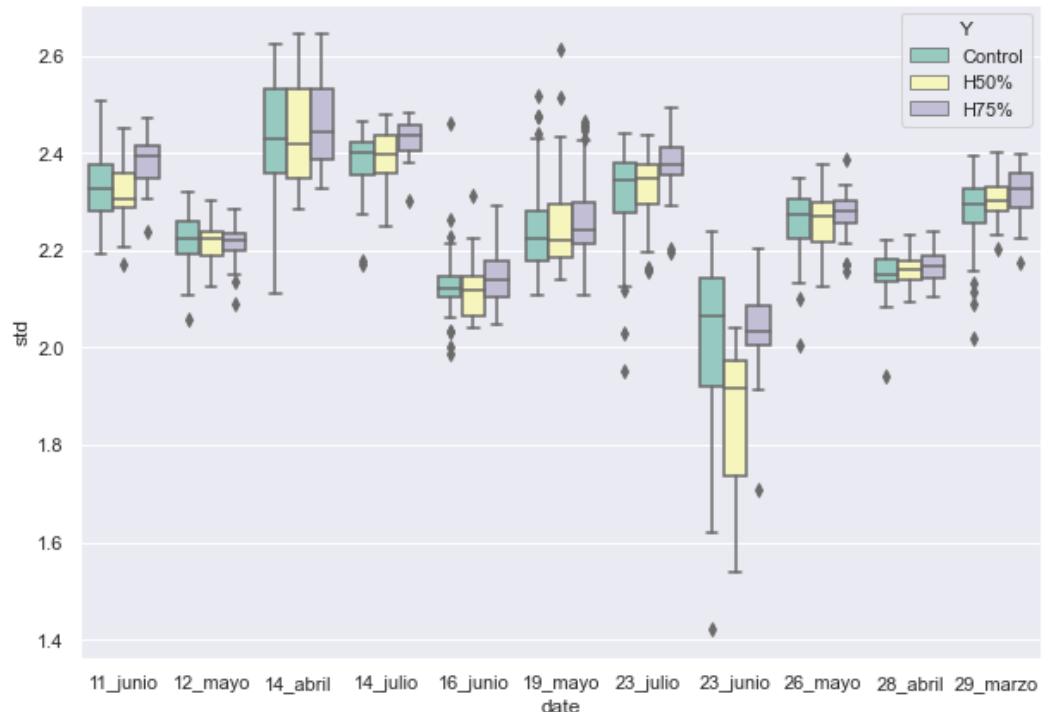
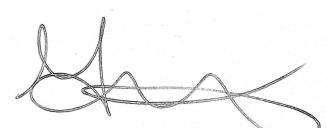


fig. 8: Gráfico de dispersión de datos por vuelo de desviación estándar de valores en el canal L de la copa del árbol



En el caso del descriptor basado en el canal L, se puede observar que si existe una tendencia general para la desviación estándar (fig 8), ya que en general los valores de desviación estándar para la deficiencia hídrica de 50% están por debajo de los demás tipos. Aun así, esta variación en la mayoría de casos es muy pequeña e incluso los valores de dispersión están altamente sobrepuertos. Por lo que al menos con este descriptor sería poco probable conseguir una clasificación eficiente.

### iii. Canal H del espacio de color HSV

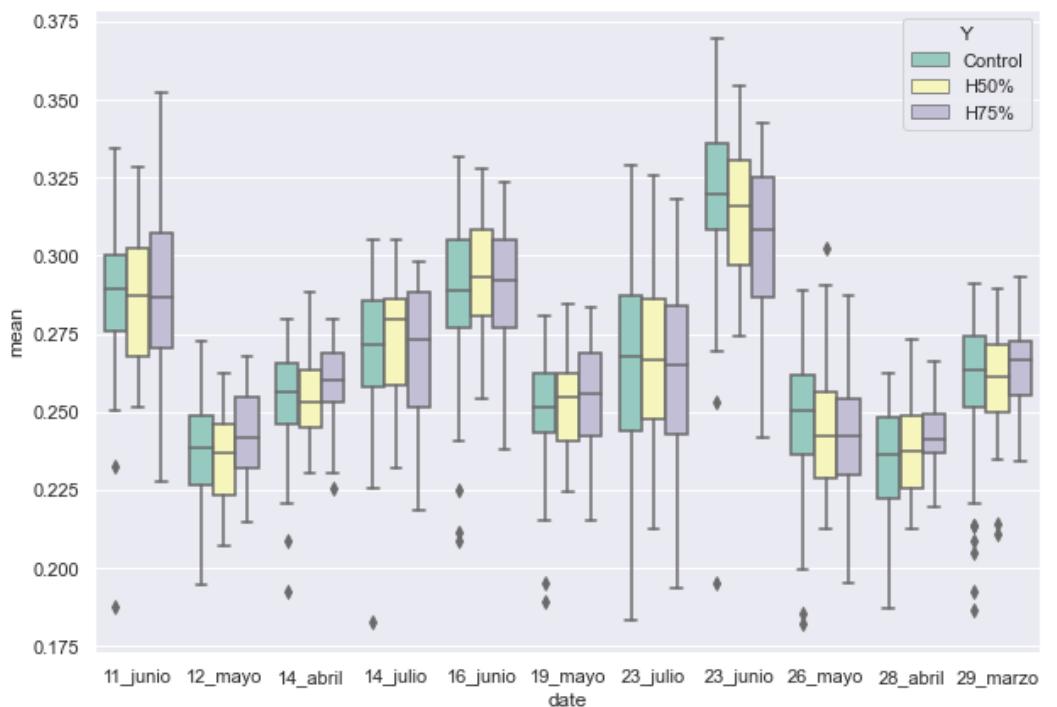
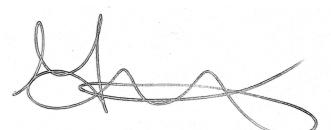


fig. 9: Gráfico de dispersión de datos por vuelo de media de valores en el canal H de la copa del árbol



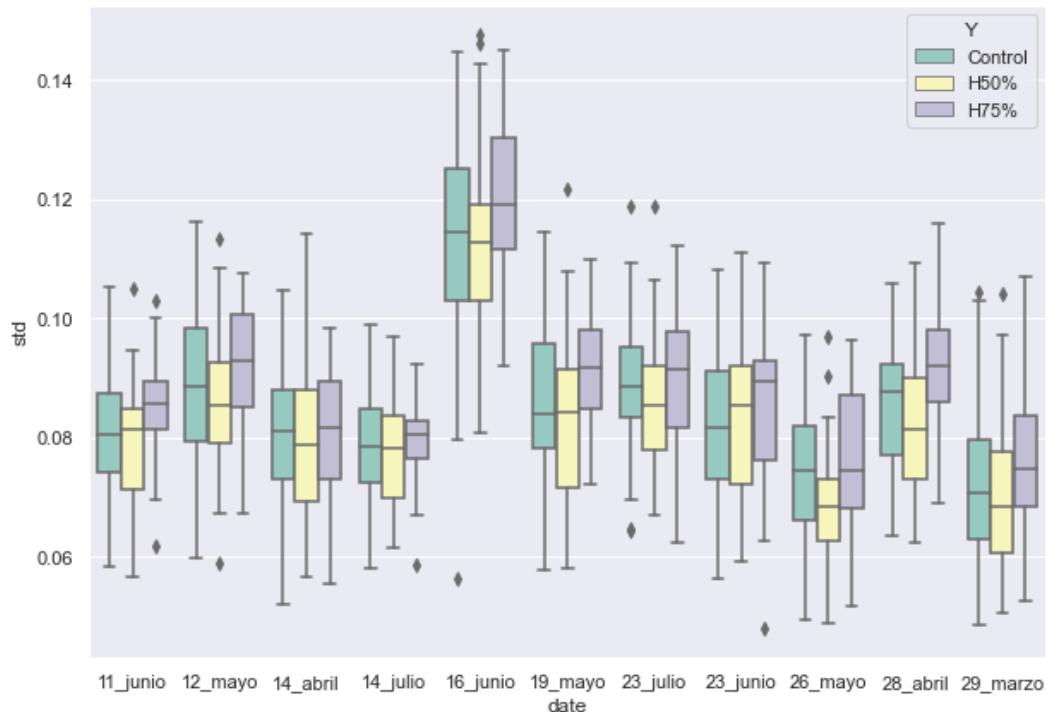
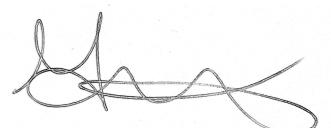


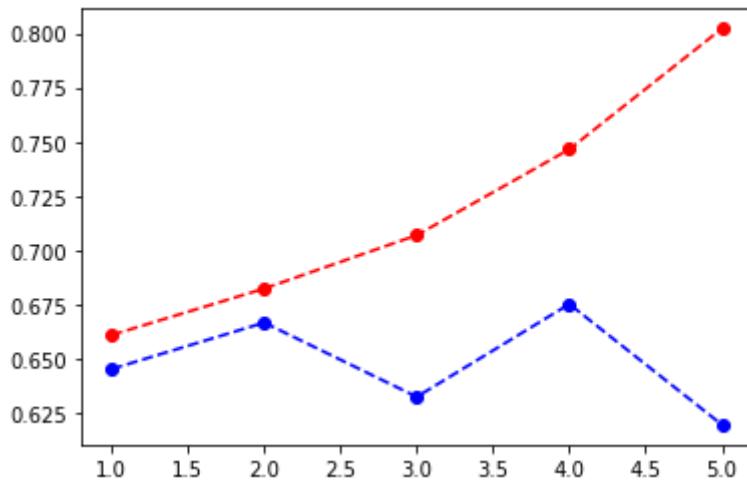
fig. 10: Gráfico de dispersión de datos por vuelo de desviación estándar de valores en el canal H de la copa del árbol

Para el caso de los descriptores basados en el canal H de HSV, se tiene mejor separabilidad en el descriptor de desviación estándar. En general la desviación estándar de los árboles sanos es más alta. Con este descriptor se puede observar mayor consistencia en la diferencia entre los parámetros. Sin embargo, la dispersión sigue superponiéndose entre las clases por lo que sería difícil realizar clasificación únicamente con este descriptor.



**b. Análisis de importancia de parámetros**

- i. Análisis con regresión logística para clasificación de árboles sanos y deficiencias de hidratación



Grado de interacción (interacción polinomial).

fig. 11: Entrenamiento de modelo de regresión logística con diferentes grados de interacción. Rojo: exactitud del modelo en entrenamiento. Azul: exactitud del modelo en test

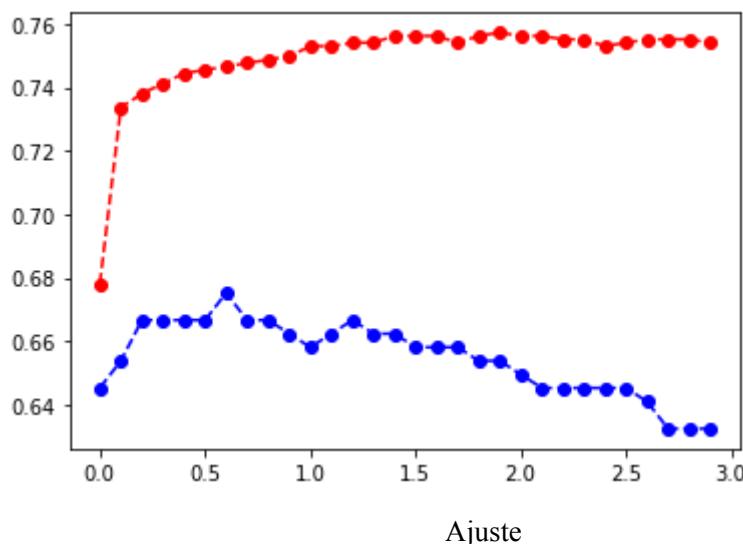


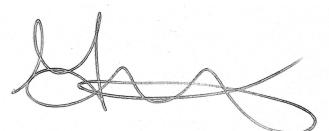
fig. 12: Entrenamiento de modelo de regresión logística con diferentes grados de ajuste. Rojo: exactitud del modelo en entrenamiento. Azul: exactitud del modelo en test

El mejor puntaje para el modelo variando la interacción entre los parámetros y el grado de ajuste fue de 0.68, para la detección de deficiencia hídrica. Además de esto. Se realizó el análisis de importancia de los parámetros. El resultado se

muestra en la siguiente lista:

- lab\_mean\* hsv\_mean
- lab\_std^2
- hsv\_mean^2
- lab\_mean\*lab\_std\*hsv\_mean
- lab\_mean\*lab\_mode\*hsv\_mean
- lab\_std\*hsv\_mean\*hsv\_std
- lab\_mode^3
- lab\_mode\*hsv\_mean\*hsv\_std
- lab\_mode\*hsv\_std^2
- lab\_mode\*hsv\_mode^2
- hsv\_mean^2\*hsv\_std
- lab\_mean^2\*lab\_mode\*hsv\_std
- lab\_std^2\*lab\_mode\*hsv\_std
- lab\_std^2\*lab\_mode\*hsv\_mode
- lab\_std^2\*hsv\_mode^2
- lab\_std\*lab\_mode^2\*hsv\_mode
- lab\_mode^3\*hsv\_mean
- lab\_mode^2\*hsv\_mode^2
- hsv\_mean^2\*hsv\_std^2

Como ya se había mencionado en el análisis estadístico anterior. Los descriptores correspondientes a los valores de los espacios de color HSV y LAB son los mas efectivos para reconocer las clases en los árboles.



ii. Análisis con árboles de decisión clasificación de árboles sanos y deficiencias de hidratación

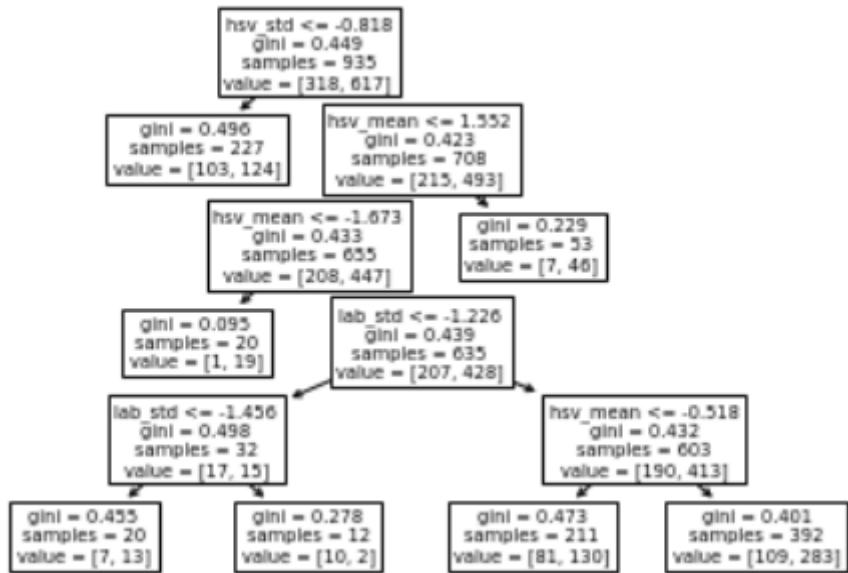
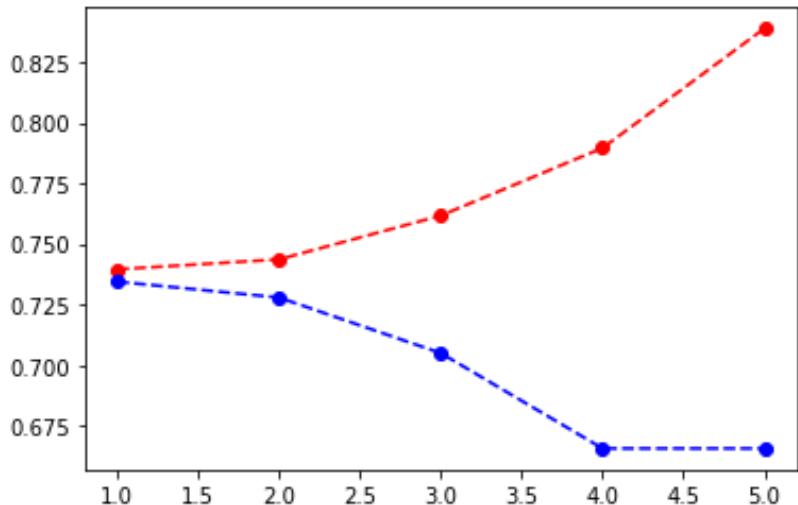


fig. 13: Árbol de decisión con las características más importantes.

Con el modelo de árboles de decisión se alcanzó la misma exactitud que el modelo anteriormente mostrado. Se debe mencionar que para este modelo la característica más importante es la desviación estándar del valor H del espacio de colores HSV.

iii. Análisis con regresión logística para clasificación de árboles sanos y deficiencia de hidratación al 50%



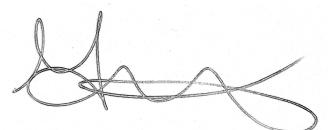
Grado de interacción (interacción polinomial).

fig. 11: Entrenamiento de modelo de regresión logística con diferentes grados de interacción. Rojo: exactitud del modelo en entrenamiento. Azul: exactitud del modelo en test

El mejor puntaje para el modelo variando la interacción entre los parámetros y el grado de ajuste fue de 0.73, para la detección de deficiencia hídrica. Además de esto. Se realizó el análisis de importancia de los parámetros. El resultado se muestra en la siguiente lista:

- hsv\_std
- hsv\_mode

Los resultados siguen siendo consistentes con el análisis anterior.



iv. Análisis con árboles de decisión clasificación de árboles sanos y deficiencia de hidratación al 50%

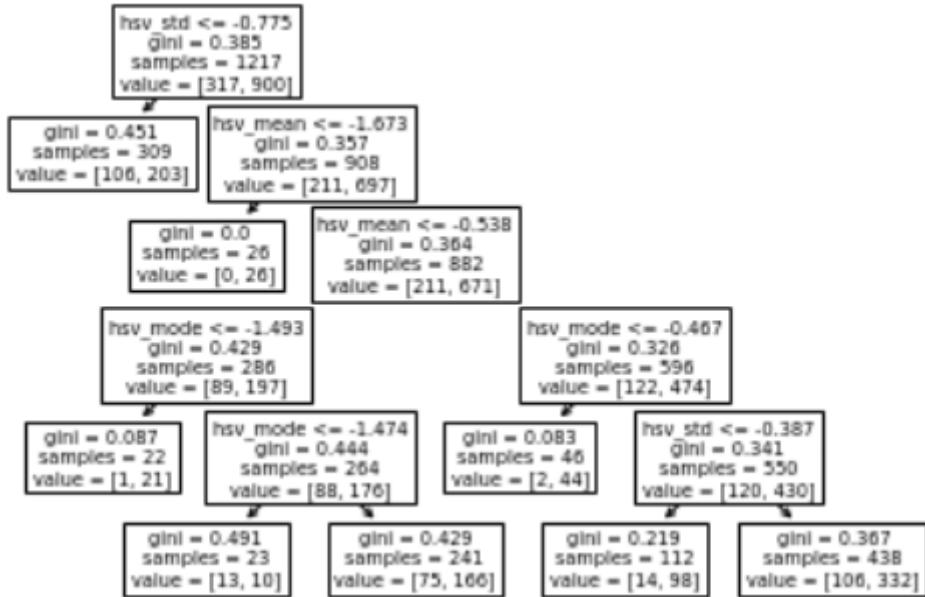
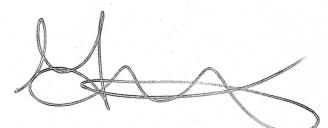


fig. 13: Árbol de decisión con las características más importantes.

Con el modelo de árboles de decisión se alcanzó la misma exactitud que el modelo anteriormente mostrado. Se debe mencionar que para este modelo la característica más importante es la desviación estándar del valor H del espacio de colores HSV.



## 5. Discusión

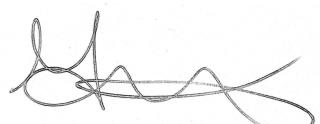
Los resultados hasta el momento muestran baja capacidad de separación para la clasificación de deficiencias. Frecuentemente, esto se debe a el ruido presente en la señal o datos fuera del rango normal de los vistos en la evidencia. Por lo que, los puntos posibles de falla serían:

- Etiquetas mal asignadas
- Descriptores poco significativos
- Outliers

El primero de estos puntos se considera debido a que los exámenes de laboratorio mostraron resultados que no son compatibles con las etiquetas basadas en la posición, este problema podría ser solucionado con métodos de aprendizaje no supervisado, con el que se podría aproximar las características intrínsecas y limpiar datos no coherentes. Por otro lado, existe la posibilidad de que los descriptores propuestos hasta el momento no capturen completamente las características correspondientes a las deficiencias buscadas, por lo que se podría usar un método de proyección no lineal sobre las imágenes con redes convolucionales (VAE) y usa el espacio latente como descriptores. Finalmente, determinar el rango en el que los datos son más coherentes sería de mucha ayuda para incrementar la exactitud del modelo de predicción.

## 6. Conclusiones

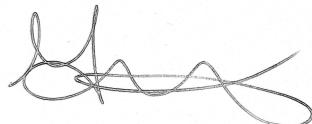
Se realizó la implementación de módulo para el manejo de los datos para el ordenamiento de la base de datos específica, la cual cuenta con funcionalidades para realizar análisis estadístico de manera general e implementar métodos de preprocesamiento de manera sencilla. Se implementó un método de segmentación de la copa de árboles para las imágenes RGB obtenidas por la cámara Phantom, el cual tiene un buen rendimiento y funciona en todos los casos, siendo el peor de los escenarios la segmentación del 50% del total de la copa del árbol. Se implementaron los métodos de generación de metadata según estudios realizados anteriormente y recomendación de los expertos en el área de biología, para este caso las características de distribución normal correspondientes a el canal H del espacio de colores HSV, el canal L del espacio de colores Lab y el porcentaje de píxeles oscuros en el canal L del espacio de colores Lab. Asimismo, se realizó el análisis de estos descriptores, observando su dispersión en el tiempo siendo que los valores que mejor separan las clases son las desviaciones estándar de HSV y Lab. Finalmente se realizó un análisis de importancia de los parámetros mencionados anteriormente. Para la clasificación de deficiencia hídrica se obtuvo una exactitud de



clasificación de 0.66, siendo las características mas importantes los valores estadísticos del canal H del espacio de color HSV. Por otro lado, para la clasificación de deficiencia hídrica la exactitud aumentó a 0.73, siendo para este caso los parámetros más importantes los valores estadísticos del canal H del espacio de colores HSV.

Es todo cuanto informo.

Atentamente,



Guillermo Ricardo Moreno Carrillo  
DNI N° 72467067

